Pemodelan Prediktif Klaim Asuransi Kesehatan Menggunakan Kombinasi Exponential Smoothing dan LightGBM

LogLoss

1. **Dimas Pasha Aki**
2. **Shata Alwan Jala**
3. **Aaron Christian**

DATA SCIENCE COMPETITION

MATHEMATICAL CHALLENGE FESTIVAL

INSTITUT TEKNOLOGI BANDUNG

2026

LEMBAR PERNYATAAN ORSINALITAS DAN DEKLARASI PENGGUNAAN KECERDASAN BUATAN GENERATIF

Kami yang bertanda tangan di bawah ini:

Nama Tim	: LogLoss
Nama Ketua Tim	: Dimas Pasha Akrilian
Nama Anggota Tim 1	: Shata Alwan Jalaluddin
Nama Anggota Tim 2	: Aaron Christian Daniel

Dengan ini menyatakan bahwa laporan yang kami sertakan dalam perlombaan DATA SCIENCE COMPETITION MCF ITB 2026 merupakan hasil karya orisinal, tidak mengandung plagiarisme dari pihak manapun, dan belum pernah diikutsertakan dalam perlombaan lain.

Kami juga mendeklarasikan penggunaan kecerdasan buatan generatif (Generative AI) dalam proses penyusunan laporan ini. Model kecerdasan buatan generatif yang digunakan adalah sebagai berikut:

Nama Model: ChatGPT

Pengembang Model: OpenAI,

Kami menggunakan model kecerdasan buatan generatif tersebut untuk keperluan berikut:

Kami menggunakan model kecerdasan buatan generatif tersebut hanya untuk memberikan rekomendasi awal terkait pemilihan metode pemodelan yang paling optimal berdasarkan karakteristik data dan tujuan prediksi. Seluruh proses analisis, pemilihan metode akhir, implementasi, evaluasi, dan penulisan laporan tetap dilakukan, ditinjau, dan dipertanggungjawabkan sepenuhnya oleh tim.

Kami menyatakan bahwa seluruh keluaran model model kecerdasan buatan generatif yang digunakan telah melalui proses peninjauan, verifikasi, dan pengolahan ulang oleh tim. Seluruh isi laporan yang dikumpulkan merupakan hasil pemahaman, analisis, dan tanggung jawab kami sebagai peserta kompetisi.

Apabila di kemudian hari kami diketahui melanggar pernyataan ini, kami siap menerima konsekuensi yang telah ditetapkan oleh panitia MCF ITB 2026 berupa sanksi diskualifikasi dari perlombaan ini. Demikian pernyataan ini dibuat dengan sebenarnya, untuk digunakan sebagaimana mestinya.

Semarang, 14 Maret 2026

Yang menyatakan,

Dimas Pasha Akrilian

Daftar Gambar

Gambar 1 Tren Bulanan Claim Frequency, Total Claim, dan Claim Severity 12
Gambar 2 Distribusi Nominal Klaim yang Disetujui dan Distribusi Logaritmiknya 13
Gambar 3 Top 10 Lokasi Rumah Sakit 13
Gambar 4 Distribusi Plan Code 14
Gambar 5 Model Baseline 15
Gambar 6 Optimasi Model 16

Daftar isi

Abstrak 3
Bab I Pendahuluan 4
1.1. Latar Belakang 4
1.2. Rumusan Masalah 4
Bab II Tinjauan Pustaka dan Metodologi 5
2.1. Feture Engineering 5
2.2. Model 7

Bab III Hasil dan Pembahasan 8
3.1. Exploratory Data Analysis 8
3.3. Hasil Prediksi 13
Bab IV Penutup 14
4.1. Kesimpulan 14
4.2. Saran untuk Perusahaan 14
Daftar Pustaka 16

Abstrak

Penelitian ini membahas prediksi *claim frequency*, *claim severity*, dan *total claim* asuransi kesehatan menggunakan data historis polis dan klaim periode Januari 2024 hingga Juli 2025. Tahapan penelitian meliputi *preprocessing data*, *exploratory data analysis*, *feature engineering*, pelatihan model, evaluasi model, serta penyusunan rekomendasi bagi perusahaan. Hasil analisis menunjukkan bahwa distribusi klaim bersifat menceng ke kanan, dengan plan code M-002, layanan rawat inap, dan rumah sakit di Singapore sebagai segmen yang memberikan kontribusi besar terhadap total klaim dan severity. Pada tahap pemodelan, pendekatan *hybrid* yang menggabungkan Exponential Smoothing, LightGBM, dan optimasi dengan Optuna memberikan performa yang lebih baik dibandingkan *baseline structural model*, dengan nilai MAPE prediksi *total claim* sebesar 2,338%. Berdasarkan model tersebut, diperoleh prediksi klaim untuk periode Agustus hingga Desember 2025 yang relatif stabil dan tetap mengikuti pola historis data. Hasil penelitian ini diharapkan dapat mendukung perusahaan dalam perencanaan beban klaim, pengendalian risiko, dan penyusunan strategi pengelolaan asuransi kesehatan yang lebih efektif.

Bab I Pendahuluan

1.1. Latar Belakang

Industri asuransi kesehatan menghadapi tantangan besar dalam mengelola ketidakpastian biaya klaim yang terus muncul dari waktu ke waktu. Ketepatan dalam memprediksi frekuensi klaim, besarnya klaim rata-rata, dan total beban klaim menjadi sangat penting untuk mendukung perencanaan keuangan, pengendalian risiko, serta pengambilan keputusan strategis perusahaan(Orros & Smith, 2012). Tanpa adanya prediksi yang baik, perusahaan berpotensi mengalami ketidakseimbangan antara premi, cadangan klaim, dan realisasi biaya kesehatan

yang harus ditanggung. Oleh karena itu, analisis prediktif berbasis data historis polis dan klaim menjadi pendekatan yang relevan untuk membantu perusahaan memahami pola klaim secara lebih akurat(Piontkowski, 2020).

Pada penelitian ini digunakan data polis asuransi kesehatan dan data klaim periode 1 Januari 2024 hingga 31 Juli 2025 untuk memprediksi *claim frequency*, *claim severity*, dan *total claim* pada periode Agustus hingga Desember 2025. Data yang tersedia memuat informasi penting, seperti *plan code*, jenis layanan, diagnosis, lokasi rumah sakit, tanggal pelayanan, dan nominal klaim yang disetujui, sehingga memberikan peluang untuk membangun model prediksi yang komprehensif. Dalam konteks tersebut, metode peramalan yang menggabungkan pendekatan *time series* dan *machine learning* dipandang mampu menangkap pola historis sekaligus memanfaatkan informasi dari fitur-fitur yang relevan(Smyl, 2020). Hasil prediksi yang dihasilkan diharapkan tidak hanya memenuhi kebutuhan kompetisi data *science*, tetapi juga memberikan rekomendasi yang bermanfaat bagi perusahaan dalam memantau segmen risiko tinggi dan merencanakan strategi pengendalian klaim.

1.2. Rumusan Masalah

Berdasarkan latar belakang penelitian, maka permasalahan yang akan dikaji dalam penelitian ini dapat dirumuskan sebagai berikut.

1. Bagaimana karakteristik data polis dan data klaim asuransi kesehatan pada periode pengamatan?
2. Bagaimana pola perkembangan *claim frequency*, *claim severity*, dan *total claim* berdasarkan data historis yang tersedia?
3. Faktor-faktor apa saja yang berpengaruh terhadap besarnya klaim asuransi kesehatan?
4. Bagaimana penerapan metode *hybrid* Exponential Smoothing dan LightGBM dalam memprediksi nilai klaim pada periode mendatang?
5. Bagaimana hasil prediksi tersebut dapat dimanfaatkan sebagai dasar rekomendasi bagi perusahaan?

1.3. Tujuan

Penelitian ini bertujuan untuk mendeskripsikan karakteristik data polis dan data klaim asuransi kesehatan pada periode Januari 2024 sampai Juli 2025 serta menganalisis pola historis *claim frequency*, *claim severity*, dan *total claim* yang terbentuk dari data tersebut. Penelitian ini juga bertujuan untuk mengidentifikasi faktor-faktor yang memengaruhi besarnya klaim berdasarkan

karakteristik polis dan klaim yang tersedia. Selain itu, penelitian ini bertujuan untuk membangun model prediksi menggunakan pendekatan *hybrid* Exponential Smoothing dan LightGBM guna memperkirakan *claim frequency*, *claim severity*, dan *total claim* pada periode Agustus sampai Desember 2025. Pada akhirnya, hasil analisis dan prediksi yang diperoleh diharapkan dapat menjadi dasar dalam menyusun rekomendasi untuk mendukung pengendalian risiko dan pengambilan keputusan pada perusahaan asuransi kesehatan.

Bab II Tinjauan Pustaka dan Metodologi

2.1. Feture Engineering

Pada tahap *feature engineering*, dilakukan pembentukan sejumlah variabel turunan untuk memperkuat kemampuan model dalam menangkap pola historis klaim asuransi kesehatan. Proses ini dilakukan setelah data klaim dan data polis dibersihkan, digabungkan, serta dibentuk ke dalam agregasi bulanan berdasarkan variabel year_month yang berasal dari tanggal pasien masuk rumah sakit. Tujuan utama dari tahap ini adalah mengubah data mentah menjadi fitur yang lebih informatif sehingga model dapat mempelajari pola frekuensi klaim, severity klaim, dan total klaim dengan lebih baik(Cerqueira et al., 2021). Selain itu, *feature engineering* juga dilakukan untuk menangkap pola musiman, volatilitas, perubahan historis, dan kontribusi tiap segmen terhadap keseluruhan klaim(Munem et al., 2020).

Adapun fitur-fitur yang dibentuk dalam penelitian ini dapat dijelaskan sebagai berikut.

1. *Monthly Aggregate Features*

   Fitur agregat bulanan dibentuk untuk merepresentasikan kondisi klaim pada setiap periode pengamatan. Pada tahap ini dihitung jumlah klaim per bulan (*frequency*), total nominal klaim yang disetujui (*total_claim*), dan *exposure* bulanan (*exposure*). Dari komponen tersebut kemudian diturunkan *severity* dan *claim rate* dengan rumus:

   $$Severity = \frac{Total\ Claim}{Frequency}$$

   $$Claim\ Rate = \frac{Frequency}{Exposure}$$

   Fitur-fitur ini menjadi dasar utama dalam pemodelan karena secara langsung menggambarkan intensitas dan besarnya beban klaim tiap bulan(Mcclenahan, n.d.).

2. *Logarithmic Transformation Features*

Untuk mengurangi pengaruh distribusi yang menceng ke kanan dan nilai klaim yang sangat besar, dilakukan transformasi log1p pada beberapa variabel utama. Transformasi ini menghasilkan fitur log_total, log_freq, log_sev, dan log_rate, dengan bentuk umum:

$$Log\ Feature\ =\ \log(1+x)$$

Penggunaan transformasi logaritmik membantu menstabilkan varians data sehingga model dapat mempelajari pola dengan lebih baik. Dengan demikian, hubungan antarvariabel menjadi lebih halus dan tidak terlalu didominasi oleh klaim-klaim ekstrem(*3.2 Time Series Components | Forecasting: Principles and Practice (3rd Ed)*, n.d.).

3. *Volatility Features*

   Untuk menangkap pola kalender, dibentuk fitur month, month_sin, month_cos, dan month_index. Fitur month menunjukkan nomor bulan, sedangkan month_sin dan month_cos digunakan untuk merepresentasikan pola musiman secara siklik dengan rumus:

$$Vol\ Ratio\ = \frac{Std6}{Roll6}$$

   Selain itu, dibuat pula indikator high_vol_regime untuk menandai periode dengan volatilitas tinggi. Fitur ini penting karena perilaku klaim pada periode stabil dan periode fluktuatif dapat memberikan pola yang berbeda terhadap hasil prediksi(*Lagged Features for Time Series Forecasting — Scikit-Learn 1.8.0 Documentation*, n.d.-a).

4. *Seasonal and Time Features*

   Untuk menangkap pola kalender, dibentuk fitur month, month_sin, month_cos, dan month_index. Fitur month menunjukkan nomor bulan, sedangkan month_sin dan month_cos digunakan untuk merepresentasikan pola musiman secara siklik dengan rumus:

$$Month\ sin = \left(\frac{2\pi\ .\ month}{12}\right)$$

$$Month\ cos = \left(\frac{2\pi\ .\ month}{12}\right)$$

   Representasi ini memungkinkan model memahami bahwa bulan Desember dan Januari tetap saling berdekatan dalam satu siklus tahunan. Sementara itu, month_index digunakan untuk menunjukkan urutan waktu secara kronologis(*Time-Related Feature Engineering — Scikit-Learn 1.8.0 Documentation*, n.d.).

5. *Lag and Rolling Mean Features*

Agar model dapat memanfaatkan informasi bulan-bulan sebelumnya, dibentuk fitur historis berupa lag1, lag2, lag3, serta roll3 pada variabel logaritmik utama. Fitur *lag* digunakan untuk menyimpan nilai periode sebelumnya, sedangkan *rolling mean* digunakan untuk menangkap rata-rata pergerakan jangka pendek. Secara umum, fitur *rolling mean* dapat dinyatakan sebagai:

$$Roll3_t = \frac{x_{t-1} + x_{t-2} + x_{t-3}}{3}$$

Dengan cara ini, model tidak hanya melihat kondisi bulan berjalan, tetapi juga mempelajari pola historis yang mendasari perubahan klaim(*Lagged Features for Time Series Forecasting — Scikit-Learn 1.8.0 Documentation*, n.d.-b) .

6. *Claim Segmentation Features*

   Selain agregasi total, dilakukan pula pembentukan fitur pada level segmen untuk menangkap heterogenitas risiko antar kelompok. Segmentasi dilakukan berdasarkan plan_code, care_type, is_cashless, dan rs_bucket. Dari masing-masing segmen tersebut dihitung frequency, total_claim, exposure, dan severity secara bulanan. Pendekatan ini bertujuan agar model dapat mengenali bahwa tiap segmen memiliki karakteristik klaim yang berbeda-beda(Athanasopoulos et al., 2009a) .

7. *Derived Features at Segment Level*

   Pada data segmentasi, dibentuk kembali fitur logaritmik, fitur kalender, fitur *lag*, dan *rolling mean* seperti pada level agregat total. Selain itu, ditambahkan momentum_total untuk menangkap arah perubahan total klaim antarperiode pada tiap segmen, dengan bentuk:

$$Momentum\ Total\ =\ Log\ Total_{t-1} - Log\ Total_{t-2}$$

   Dibentuk juga seg_weight untuk menunjukkan kontribusi relatif suatu segmen terhadap total frekuensi klaim pada bulan yang sama, dengan rumus:

$$Seg\ Weight\ =\ \frac{Frequency\ of\ Segment}{Total\ Frequency\ ini\ the\ Same\ Month}$$

   Fitur-fitur ini membantu model memahami segmen mana yang dominan dan segmen mana yang mengalami perubahan pola lebih cepat dibandingkan segmen lainnya(Athanasopoulos et al., 2009b) .

8. Pemilihan data akhir untuk pemodelan

Setelah seluruh fitur dibentuk, observasi awal yang belum memiliki histori cukup untuk membentuk fitur *lag* dihapus dari data pelatihan. Langkah ini dilakukan agar model hanya menerima data yang lengkap dan konsisten. Dengan demikian, proses pelatihan menjadi lebih stabil karena tidak terganggu oleh banyak nilai kosong pada awal periode. Tahap ini juga memastikan bahwa setiap observasi yang digunakan memang memiliki informasi historis yang memadai(*Lagged Features for Time Series Forecasting — Scikit-Learn 1.8.0 Documentation*, n.d.-c).

Secara keseluruhan, tahap *feature engineering* dalam penelitian ini berperan penting dalam mengubah data mentah menjadi kumpulan fitur yang lebih representatif terhadap pola klaim asuransi kesehatan. Fitur-fitur yang dibentuk tidak hanya mencerminkan kondisi agregat klaim, tetapi juga menangkap pola waktu, volatilitas, histori, dan segmentasi risiko. Melalui pendekatan ini, model diharapkan mampu menghasilkan prediksi yang lebih akurat dan lebih stabil untuk periode yang akan datang.

2.2. Model

Pada penelitian ini, proses pemodelan dilakukan untuk memprediksi tiga target utama, yaitu *claim frequency*, *claim severity*, dan *total claim* pada periode Agustus sampai Desember 2025. Pemodelan disusun dengan pendekatan bertahap, dimulai dari model dasar (*baseline structural model*) sebagai pembanding, kemudian dikembangkan menjadi model *hybrid* yang menggabungkan metode deret waktu dan *machine learning*. Pendekatan ini dipilih karena data klaim bulanan memiliki pola historis yang bersifat fluktuatif, sehingga diperlukan model yang mampu menangkap pola waktu sekaligus memanfaatkan informasi dari fitur-fitur turunan(Sun & Qin, 2026). Selain itu, hasil prediksi dijaga tetap konsisten secara struktural dengan hubungan bahwa *total claim* merupakan hasil perkalian antara *claim frequency* dan *claim severity(Jed Frees, 2014a)*.

Adapun tahapan pemodelan yang digunakan dalam penelitian ini adalah sebagai berikut.

1. Baseline structural model

   Model dasar dibangun menggunakan agregasi bulanan yang terdiri atas frequency, total_claim, exposure, severity, dan claim_rate. Pada model ini, total_claim diprediksi menggunakan metode Exponential Smoothing, sedangkan frequency diperkirakan menggunakan rata-rata *claim rate* beberapa bulan terakhir yang dikalikan dengan nilai *exposure*. Selanjutnya, severity dihitung secara konsisten sebagai rasio antara

total_claim terhadap frequency. Model ini digunakan sebagai acuan awal untuk melihat performa dasar sebelum dilakukan optimasi lebih lanjut(Holt, 2004).

2. Model hybrid Exponential Smoothing dan LightGBM

   Untuk meningkatkan akurasi prediksi, digunakan model *hybrid* yang menggabungkan Exponential Smoothing (ETS) dan LightGBM. ETS digunakan untuk menangkap pola deret waktu pada total_claim, terutama kecenderungan historis jangka pendek. Sementara itu, LightGBM digunakan untuk memanfaatkan fitur-fitur hasil *feature engineering*, seperti fitur musiman, *lag*, dan *rolling mean*. Hasil prediksi dari kedua model kemudian digabungkan dengan bobot tertentu agar diperoleh prediksi yang lebih stabil dan adaptif(Ke et al., n.d.).

3. Optimasi parameter dengan Optuna

   Pada model hybrid, dilakukan optimasi parameter menggunakan Optuna untuk mendapatkan kombinasi parameter terbaik. Parameter yang dioptimasi meliputi bobot penggabungan ETS dan LightGBM (alpha), *learning rate*, jumlah daun (num_leaves), serta faktor *shrinkage*. Proses ini dilakukan untuk meminimalkan nilai MAPE pada data validasi. Dengan optimasi tersebut, model diharapkan memiliki performa yang lebih baik dibandingkan model baseline(Akiba et al., 2019).

4. Recursive forecasting

   Prediksi dilakukan dengan pendekatan recursive forecasting, yaitu hasil prediksi pada satu bulan digunakan kembali sebagai bagian dari input untuk memprediksi bulan berikutnya. Pendekatan ini digunakan karena target yang diprediksi terdiri atas beberapa periode ke depan, yaitu lima bulan berturut-turut dari Agustus sampai Desember 2025. Dengan cara ini, model dapat meniru situasi prediksi nyata ketika data aktual untuk periode mendatang belum tersedia. Metode ini juga sesuai untuk data deret waktu bulanan yang diproyeksikan secara berurutan(*Recursive Multi-Step Forecasting - Skforecast Docs*, n.d.).

5. Konsistensi antar target prediksi

   Dalam penelitian ini, ketiga target prediksi tidak diperlakukan sepenuhnya terpisah. Nilai total_claim diprediksi melalui model utama, frequency diperkirakan menggunakan pendekatan *claim rate* yang stabil, sedangkan severity dihitung dari pembagian total_claim terhadap frequency. Pendekatan ini digunakan agar hasil prediksi tetap konsisten secara matematis dan lebih mudah diinterpretasikan. Dengan

demikian, model tidak hanya berfokus pada akurasi, tetapi juga menjaga hubungan logis antarvariabel(Jed Frees, 2014b) .

6. Evaluasi model

   Kinerja model dievaluasi menggunakan Mean Absolute Percentage Error (MAPE). Pada tahap awal, model baseline digunakan untuk mengevaluasi prediksi frequency, severity, dan total_claim. Setelah itu, model hybrid dievaluasi terutama pada kemampuan memprediksi total_claim, karena variabel ini menjadi komponen utama dalam pembentukan nilai prediksi akhir. Hasil evaluasi ini digunakan untuk membandingkan performa antar pendekatan dan memilih model yang paling sesuai untuk tahap prediksi(Hyndman & Koehler, 2006) .

Secara keseluruhan, metode pemodelan dalam penelitian ini menggabungkan kekuatan pendekatan statistik dan *machine learning* untuk menghasilkan prediksi yang lebih stabil dan akurat. Model baseline digunakan sebagai acuan awal, sedangkan model hybrid digunakan sebagai model utama karena mampu memanfaatkan pola historis dan informasi fitur secara bersamaan. Dengan pendekatan ini, proses prediksi diharapkan dapat memberikan hasil yang lebih baik untuk mendukung analisis klaim asuransi kesehatan pada periode mendatang.

Bab III Hasil dan Pembahasan

3.1. Exploratory Data Analysis

1. Tren Bulanan Claim Frequency, Total Claim, dan Claim Severity

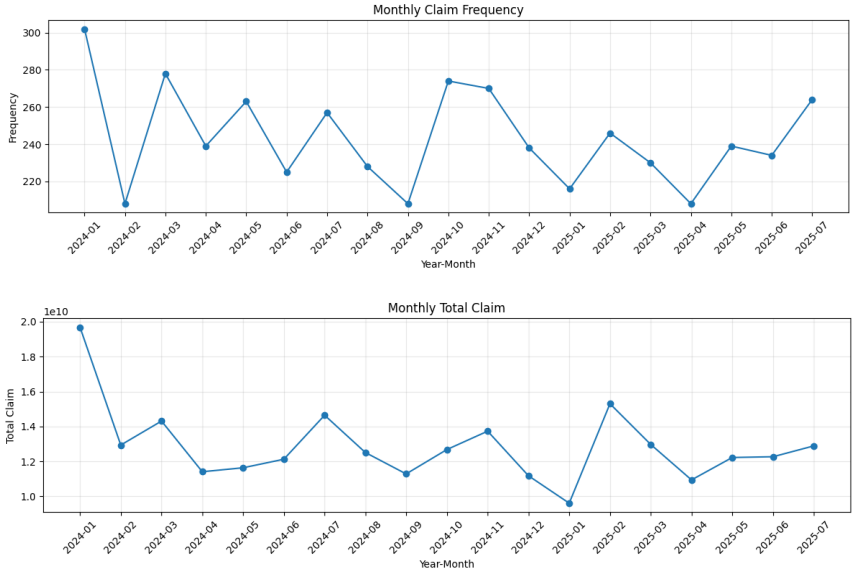

Gambar 1 *Tren Bulanan Claim Frequency, Total Claim, dan Claim Severity*

Berdasarkan gambar di atas, terlihat bahwa *claim frequency*, *total claim*, dan *claim severity* mengalami fluktuasi sepanjang periode Januari 2024 hingga Juli 2025. Perubahan tersebut menunjukkan bahwa pola klaim tidak bersifat konstan dari bulan ke bulan. Beberapa periode memperlihatkan kenaikan maupun penurunan yang cukup jelas, baik pada jumlah klaim maupun besarnya nilai klaim. Kondisi ini menunjukkan bahwa data klaim memiliki karakteristik deret waktu yang dinamis dan perlu dianalisis lebih lanjut melalui pendekatan peramalan.

2. Distribusi Nominal Klaim yang Disetujui dan Distribusi Logaritmiknya

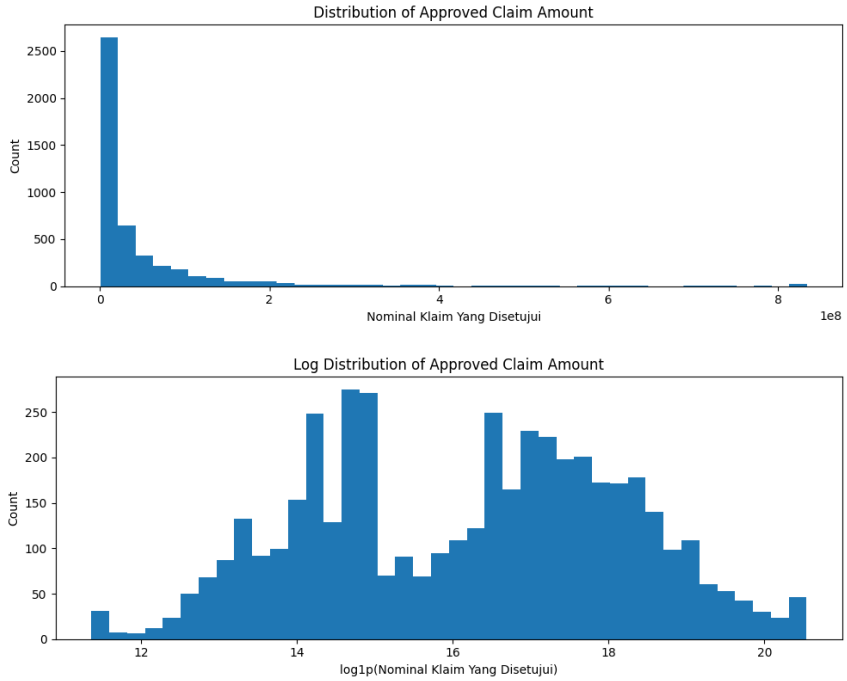

Gambar 2 *Distribusi Nominal Klaim yang Disetujui dan Distribusi Logaritmiknya*

Berdasarkan gambar di atas, distribusi nominal klaim yang disetujui menunjukkan pola yang menceng ke kanan, yang berarti sebagian besar klaim bernilai relatif kecil, tetapi terdapat sejumlah klaim dengan nilai sangat besar. Pola ini menunjukkan adanya ketimpangan distribusi dan keberadaan nilai ekstrem pada data klaim. Setelah dilakukan transformasi logaritmik, distribusi data tampak lebih stabil dan lebih mudah dianalisis. Oleh karena itu, transformasi log digunakan untuk membantu proses pemodelan agar lebih robust terhadap variasi nilai klaim yang besar.

3. Top 10 Lokasi Rumah Sakit

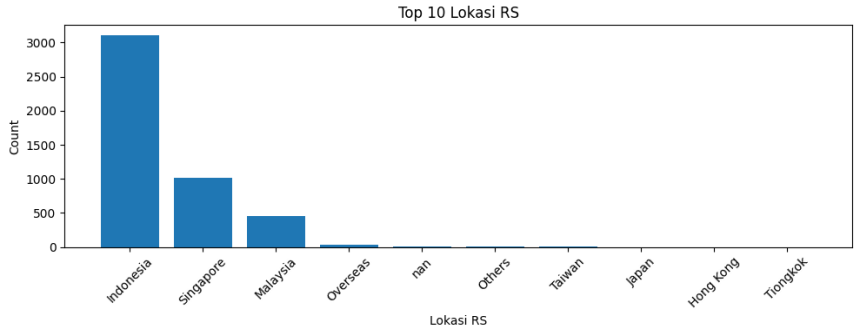

Gambar 3 *Top 10 Lokasi Rumah Sakit*

Berdasarkan gambar di atas jumlah klaim paling banyak berasal dari rumah sakit yang berlokasi di Indonesia, diikuti oleh Singapore dan Malaysia. Sementara itu, lokasi lainnya memberikan kontribusi klaim yang relatif lebih kecil. Temuan ini menunjukkan bahwa lokasi rumah sakit memiliki distribusi yang tidak merata dalam data klaim. Dengan demikian, lokasi rumah sakit dapat dipertimbangkan sebagai salah satu variabel penting dalam analisis karakteristik klaim.

4. Distribusi Plan Code

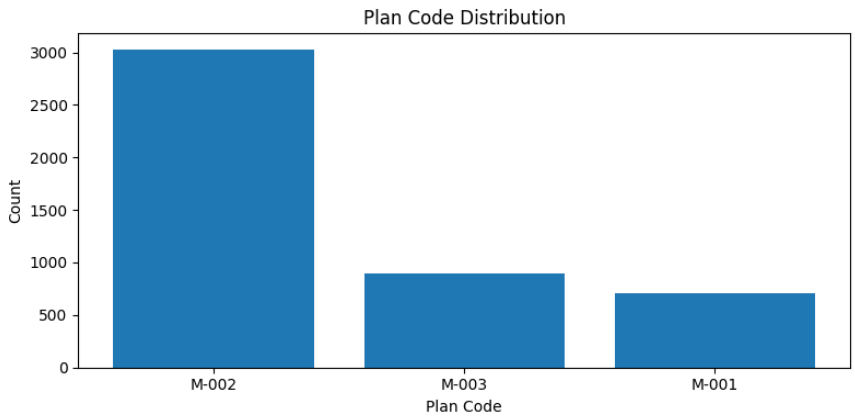

Gambar 4 *Distribusi Plan Code*

Berdasarkan gambar di atas, plan code M-002 merupakan kategori yang paling dominan dalam data klaim, sedangkan M-003 dan M-001 memiliki proporsi yang lebih kecil. Hal ini menunjukkan bahwa distribusi klaim antar plan code tidak seimbang. Perbedaan komposisi tersebut dapat memengaruhi pola frekuensi maupun besarnya klaim pada masing-masing kelompok. Oleh karena itu, plan code menjadi salah satu variabel yang relevan untuk dianalisis lebih lanjut dalam proses pemodelan.

3.2. Machine Learning Training

Pada tahap *machine learning training*, dilakukan pelatihan model untuk memprediksi *claim frequency*, *claim severity*, dan *total claim* berdasarkan data bulanan yang telah melalui tahap *preprocessing* dan *feature engineering*. Proses pelatihan dilakukan dengan mempertahankan urutan waktu agar pola historis klaim dapat digunakan untuk memprediksi periode berikutnya secara berurutan. Pendekatan ini dipilih karena permasalahan yang dianalisis merupakan deret waktu dengan horizon prediksi beberapa bulan ke depan. Selain itu, pemodelan dilakukan secara bertahap agar dapat dibandingkan antara model dasar dan model yang telah dioptimasi.

Adapun tahapan pelatihan model yang digunakan adalah sebagai berikut.

1. Model baseline

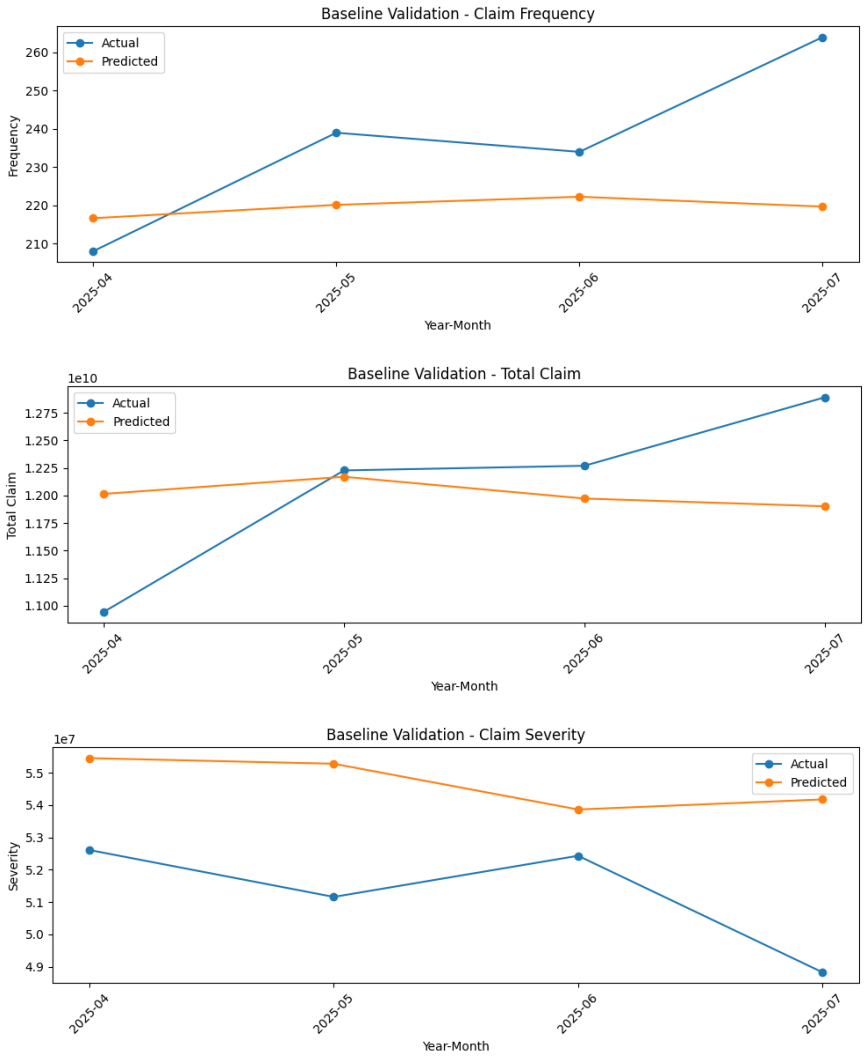

Gambar 5 Model Baseline

Model awal yang digunakan adalah *baseline structural model*. Pada model ini, *total claim* diprediksi menggunakan Exponential Smoothing, sedangkan *claim frequency* diperkirakan dari rata-rata *claim rate* beberapa bulan terakhir. Nilai *claim severity* kemudian dihitung sebagai rasio antara *total claim* dan *claim frequency*. Model ini digunakan sebagai pembanding awal sebelum diterapkan model yang lebih kompleks.

2. Model hybrid

Untuk meningkatkan akurasi, digunakan model *hybrid* yang menggabungkan Exponential Smoothing dan LightGBM. Exponential Smoothing digunakan untuk menangkap pola historis *total claim*, sedangkan LightGBM digunakan untuk

memanfaatkan fitur-fitur hasil *feature engineering*. Kedua model digabungkan agar prediksi yang dihasilkan lebih stabil dan adaptif terhadap pola data.

3. Optimasi model

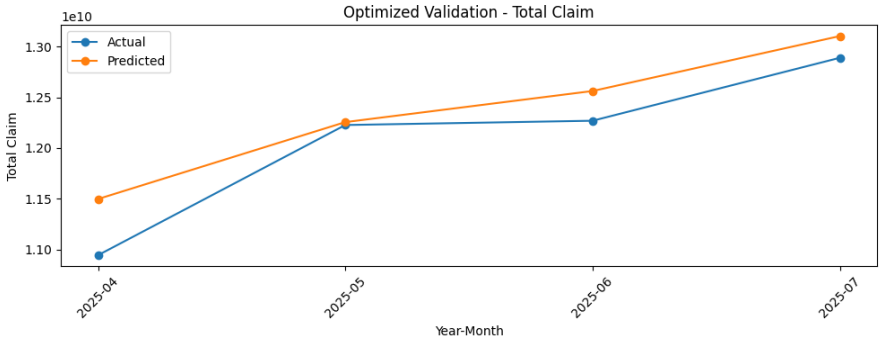

Gambar 6 Optimasi Model

Parameter model *hybrid* dioptimasi menggunakan Optuna untuk memperoleh kombinasi parameter terbaik. Proses ini bertujuan meminimalkan nilai kesalahan prediksi pada data validasi. Dengan optimasi tersebut, model yang dipilih diharapkan mampu memberikan hasil prediksi yang lebih akurat.

4. Hasil evaluasi

Model	Frequency MAPE (%)	Total Claim MAPE (%)	Severity MAPE (%)	Estimated Score (%)
Baseline Structural Model	8.4632	5.0886	6.7861	6.7793
Hybrid ETS + LightGBM + Optuna	-	2.3380	-	-

Tabel 1 Hasil evaluasi Model

Parameter	**Nilai**
alpha	0.4125238519444799
lr	0.029976817637997012
leaves	3
shrink	0.9795335810303368

Tabel 2 Parameter Terbaik Model Hybrid

Hasil evaluasi pada Tabel 3.1 menunjukkan bahwa *baseline structural model* masih menghasilkan tingkat kesalahan prediksi yang relatif lebih tinggi, dengan nilai MAPE

sebesar 8,463% pada *claim frequency*, 5,089% pada *total claim*, dan 6,786% pada *claim severity*. Setelah dilakukan pengembangan model menggunakan pendekatan *hybrid* Exponential Smoothing dan LightGBM serta optimasi parameter menggunakan Optuna, nilai MAPE prediksi *total claim* berhasil diturunkan menjadi 2,338%. Penurunan nilai kesalahan tersebut menunjukkan bahwa model *hybrid* memiliki kemampuan yang lebih baik dalam menangkap pola historis data klaim. Oleh karena itu, model *hybrid* digunakan sebagai model utama pada tahap prediksi akhir.

3.3. Hasil Prediksi

Berdasarkan model *hybrid* yang telah dilatih, diperoleh hasil prediksi *claim frequency*, *claim severity*, dan *total claim* untuk periode Agustus sampai Desember 2025. Hasil prediksi menunjukkan bahwa nilai *claim frequency* cenderung berada pada kisaran yang relatif stabil, sedangkan *claim severity* dan *total claim* mengalami fluktuasi antarbuan dengan perbedaan yang tidak terlalu ekstrem. Kondisi ini menunjukkan bahwa pola klaim pada periode mendatang diperkirakan masih mengikuti karakter historis yang telah terbentuk pada data sebelumnya. Secara umum, hasil prediksi tersebut dapat digunakan sebagai dasar untuk memperkirakan beban klaim perusahaan serta mendukung perencanaan pengendalian risiko pada periode mendatang.

Bab IV Penutup

4.1. Kesimpulan

Berdasarkan hasil analisis, data klaim asuransi kesehatan pada periode Januari 2024 hingga Juli 2025 menunjukkan pola yang fluktuatif pada *claim frequency*, *claim severity*, dan *total claim*. Hasil *exploratory data analysis* menunjukkan bahwa distribusi nilai klaim bersifat menceng ke kanan, sehingga terdapat sejumlah kecil klaim bernilai sangat besar yang memberikan kontribusi signifikan terhadap total klaim. Selain itu, segmentasi data menunjukkan bahwa plan code M-002, jenis layanan rawat inap, dan rumah sakit di Singapore merupakan segmen yang paling dominan dalam membentuk total klaim maupun severity. Temuan ini menunjukkan bahwa beban klaim perusahaan dipengaruhi oleh perbedaan karakteristik polis, jenis layanan, dan lokasi rumah sakit.

Pada tahap pemodelan, pendekatan *hybrid* yang menggabungkan Exponential Smoothing, LightGBM, dan optimasi dengan Optuna memberikan performa yang lebih baik dibandingkan *baseline structural model*. Hasil evaluasi menunjukkan bahwa model *baseline*

menghasilkan *estimated score* sebesar 6,779%, sedangkan model *hybrid* mampu menurunkan nilai MAPE prediksi *total claim* menjadi 2,338%. Berdasarkan model tersebut, diperoleh prediksi *claim frequency*, *claim severity*, dan *total claim* untuk periode Agustus hingga Desember 2025 yang relatif stabil dan tetap mengikuti pola historis data. Dengan demikian, hasil penelitian ini dapat digunakan sebagai dasar dalam mendukung perencanaan beban klaim, pengendalian risiko, dan penyusunan rekomendasi strategis bagi perusahaan asuransi kesehatan.

4.2. Saran untuk Perusahaan

1. Claim Summary by Plan Code

Plan Code	Frequency	Total Claim	Severity	Share of Total Claim (%)
M-002	3028	163864300000	54116340	67.06
M-001	704	40484480000	57506370	16.57
M-003	895	40009450000	44703300	16.37

Berdasarkan ringkasan klaim menurut *plan code*, terlihat bahwa plan code M-002 memberikan kontribusi terbesar terhadap total klaim, yaitu sebesar 67,06%. Selain itu, frekuensi klaim pada plan ini juga jauh lebih tinggi dibandingkan plan lainnya, sehingga menunjukkan bahwa M-002 merupakan segmen utama yang perlu mendapat perhatian khusus. Oleh karena itu, perusahaan disarankan untuk melakukan evaluasi lebih lanjut terhadap karakteristik manfaat, pola penggunaan layanan, serta profil risiko peserta pada plan code M-002. Langkah ini penting agar perusahaan dapat menyusun strategi pengendalian biaya yang lebih terarah pada segmen plan dengan kontribusi klaim tertinggi.

2. Claim Summary by Type of Care

Care Type	Frequency	Total Claim	Severity	Share of Total Claim (%)
IP	2258	178278900000	78954340	72.96
OP	1940	45303370000	23352250	18.54
ODC	281	16732370000	59545790	6.85
ODS	111	3393484000	30571920	1.39
NAN	37	650100700	17570290	0.27

Berdasarkan ringkasan klaim menurut jenis layanan perawatan, diketahui bahwa layanan IP (Inpatient/rawat inap) memiliki kontribusi total klaim terbesar, yaitu

72,96%, sekaligus memiliki nilai severity yang paling tinggi. Hal ini menunjukkan bahwa rawat inap merupakan sumber beban klaim utama dibandingkan jenis layanan lainnya. Oleh karena itu, perusahaan disarankan untuk memperkuat pengawasan terhadap klaim rawat inap, terutama pada kasus-kasus dengan biaya tinggi dan frekuensi penggunaan yang berulang. Selain itu, evaluasi kebijakan manfaat rawat inap dan pengendalian biaya perawatan perlu dilakukan untuk menekan beban klaim yang berlebihan.

3. Claim Summary by Hospital Location Group

Hospital Location Group	Frequency	Total Claim	Severity	Share of Total Claim (%)
SG	1019	118027200000	115826500	48.30
ID	3102	103948600000	33510200	42.54
MY	456	17830080000	39101060	7.30
OTHER	50	4552311000	91046230	1.86

Berdasarkan kelompok lokasi rumah sakit, rumah sakit di Singapore (SG) memiliki kontribusi total klaim terbesar, yaitu 48,30%, serta severity tertinggi dibandingkan lokasi lainnya. Temuan ini menunjukkan bahwa layanan kesehatan di luar negeri, khususnya Singapore, memberikan dampak signifikan terhadap peningkatan biaya klaim perusahaan. Oleh karena itu, perusahaan disarankan untuk melakukan monitoring lebih ketat terhadap klaim rumah sakit luar negeri, termasuk evaluasi pola rujukan, kebutuhan layanan, dan efektivitas biaya perawatan. Dengan demikian, perusahaan dapat lebih fokus dalam mengendalikan segmen lokasi rumah sakit yang berisiko tinggi terhadap total klaim.

4. High-Value Claim Analysis

Metric	**Value**
95th Percentile Cut-off	223325827
99th Percentile Cut-off	633686130
Share of Total Claim from Top 5% Claims (%)	42.81
Share of Total Claim from Top 1% Claims (%)	15.09

Berdasarkan analisis klaim bernilai tinggi, diperoleh hasil bahwa top 5% claims menyumbang 42,81% dari total klaim, sedangkan top 1% claims menyumbang 15,09%

dari total klaim. Hasil ini menunjukkan bahwa sebagian kecil klaim memiliki kontribusi yang sangat besar terhadap keseluruhan beban klaim perusahaan. Oleh karena itu, perusahaan disarankan untuk membangun sistem *early warning* dan monitoring khusus terhadap klaim bernilai besar agar penanganan dapat dilakukan lebih cepat dan tepat. Strategi ini penting untuk mengurangi risiko lonjakan total klaim yang berasal dari klaim-klaim ekstrem.

Berdasarkan keseluruhan hasil analisis, perusahaan disarankan untuk memusatkan perhatian pada segmen-segmen yang memberikan kontribusi terbesar terhadap total klaim, yaitu plan code M-002, layanan rawat inap, dan rumah sakit yang berlokasi di Singapore. Ketiga segmen tersebut terbukti memiliki frekuensi, severity, maupun kontribusi total klaim yang relatif lebih tinggi dibandingkan segmen lainnya. Dengan memfokuskan pengawasan pada segmen-segmen tersebut, perusahaan dapat melakukan pengendalian biaya secara lebih efektif dan terarah. Selain itu, evaluasi berkala terhadap manfaat polis dan pola utilisasi layanan kesehatan juga perlu dilakukan untuk menjaga keseimbangan antara kebutuhan peserta dan beban klaim perusahaan.

Di samping itu, perusahaan juga perlu memberikan perhatian khusus terhadap klaim bernilai tinggi karena sebagian kecil klaim terbukti menyumbang porsi yang besar terhadap total klaim. Penerapan sistem monitoring, deteksi dini, dan pengawasan terhadap klaim besar dapat membantu perusahaan dalam mengurangi risiko lonjakan biaya secara mendadak. Hasil analisis ini menunjukkan bahwa strategi pengendalian klaim sebaiknya tidak hanya berfokus pada volume klaim, tetapi juga pada segmen dengan severity tinggi dan konsentrasi klaim besar. Dengan demikian, perusahaan dapat menyusun kebijakan yang lebih tepat dalam mendukung efisiensi biaya, pengendalian risiko, dan keberlanjutan pengelolaan asuransi kesehatan.

Daftar Pustaka

3.2 Time series components | Forecasting: Principles and Practice (3rd ed). (n.d.). Retrieved March 15, 2026, from https://otexts.com/fpp3/components.html?utm_source=chatgpt.com

Athanasopoulos, G., Ahmed, R. A., & Hyndman, R. J. (2009a). Hierarchical forecasts for Australian domestic tourism. *International Journal of Forecasting*, *25*(1), 146–166. https://doi.org/10.1016/j.ijforecast.2008.07.004

Athanasopoulos, G., Ahmed, R. A., & Hyndman, R. J. (2009b). Hierarchical forecasts for Australian domestic tourism. *International Journal of Forecasting*, *25*(1), 146–166. https://doi.org/10.1016/j.ijforecast.2008.07.004

Cerqueira, V., Moniz, N., Soares, C., Verdonck, T., Baesens, B., Óskarsdóttir, M., & vanden Broucke, S. (2021). VEST: automatic feature engineering for forecasting. *Machine Learning 2021 113:7*, *113*(7), 4523–4545. https://doi.org/10.1007/s10994-021-05959-y

Lagged features for time series forecasting — scikit-learn 1.8.0 documentation. (n.d.-a). Retrieved March 15, 2026, from https://scikit-learn.org/stable/auto_examples/applications/plot_time_series_lagged_features.html

Lagged features for time series forecasting — scikit-learn 1.8.0 documentation. (n.d.-b). Retrieved March 15, 2026, from https://scikit-learn.org/stable/auto_examples/applications/plot_time_series_lagged_features.html

Lagged features for time series forecasting — scikit-learn 1.8.0 documentation. (n.d.-c). Retrieved March 15, 2026, from https://scikit-learn.org/stable/auto_examples/applications/plot_time_series_lagged_features.html

Mcclenahan, C. L. (n.d.). *Chapter 3 RATEMAKING*.

Munem, M., Rubaith Bashar, T. M., Roni, M. H., Shahriar, M., Shawkat, T. B., & Rahaman, H. (2020). Electric power load forecasting based on multivariate LSTM neural network using bayesian optimization. *2020 IEEE Electric Power and Energy Conference, EPEC 2020*, *335*(3), 137981. https://doi.org/10.1109/EPEC48502.2020.9320123

Orros, G. C., & Smith, J. (2012). Enterprise risk management for health insurance from an actuarial perspective. *British Actuarial Journal*, *17*(2), 259–314. https://doi.org/10.1017/s1357321712000062

Piontkowski, J. (2020). Forecasting health expenses using a functional data model. *Annals of Actuarial Science*, *14*(1), 72–82. https://doi.org/10.1017/S1748499519000046

Smyl, S. (2020). A hybrid method of exponential smoothing and recurrent neural networks for time series forecasting. *International Journal of Forecasting*, *36*(1), 75–85. https://doi.org/10.1016/j.ijforecast.2019.03.017

Time-related feature engineering — scikit-learn 1.8.0 documentation. (n.d.). Retrieved March 15, 2026, from https://scikit-learn.org/stable/auto_examples/applications/plot_cyclical_feature_engineering.html